



## JDA joint-distribution-adaptation

cross-domain knowledge adaptation problem

在一个原则性矩阵维过程中同时适应边缘分布和条件分布，并构造出有效且鲁棒的新特征表示法，以有效应对大量分布差异。

域间具有不同的边缘分布和条件分布，且目标域无标签。

Assumptions:

$$x_s = x_t, y_s = y_t \quad p_s(x_s) \neq p_t(x_t), \quad Q_s(y_s|x_s) \neq Q_t(y_t|x_t)$$

通过特征变换  $T$  来适应联合分布

$$\min_T \| E_{p_s}(x_s)[T(x_s), y_s] - E_{p_t}(x_t)[T(x_t), y_t] \|^2$$

$$\approx \| E_{p_s}(x_s)[T(x_s)] - E_{p_t}(x_t)[T(x_t)] \|^2 \quad \text{margin distribution}$$

$$+ \| E_{Q_s}(y_s|x_s)[y_s|T(x_s)] - E_{Q_t}(y_t|x_t)[y_t|T(x_t)] \|^2 \quad \begin{matrix} \text{condition} \\ \text{distribution} \end{matrix}$$

迭代伪标签优化策略 来迭代优化变换  $T$  和分类器  $f$

1) PCA: 先用PCA降维，进行 data reconstruction.  $n = n_s + n_t$  (concat)

$$\max \operatorname{tr}(A^T X H X^T A) \quad \text{where } X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{m \times n} \quad (n \text{ sample, } m \text{维})$$

$$A^T A = I \quad H = I - \frac{1}{n} I^T \quad (n = n_s + n_t)$$

正交变换矩阵  $A$

$X$  的协方差矩阵  $X^T H X$  降维后数据  $Z = [z_1, \dots, z_n] = A^T X \quad A \in \mathbb{R}^{m \times k}$

$Z \in \mathbb{R}^{k \times n}$  所以最大化的是降维后数据的协方差矩阵  $Z^T H Z = A^T X^T H X A$

$A$ : 正交变换矩阵 (要求为矩阵)

特征分解  $X^T H X^T A = A \Phi \quad \Phi = \operatorname{diag}(\phi_1, \phi_2, \dots, \phi_k) \in \mathbb{R}^{k \times k}$  前  $k$  个最大特征值

2) margin distribution Adaptation

用 NMD 测量经PCA处理后的域间差边缘分布差异

$$\left\| \frac{1}{n_s} \sum_{i=1}^{n_s} A^T x_i - \frac{1}{n_t} \sum_{j=n_s+1}^{n_s+n_t} A^T x_j \right\|^2 = \operatorname{tr}(A^T X M_0 X^T A)$$

$$\left\| \frac{1}{n_s} \sum_{i=1}^{n_s} z_i - \frac{1}{n_t} \sum_{j=n_s+1}^{n_s+n_t} z_j \right\|^2$$

(3) 最小化

$$(M_0)_{i,j} = \begin{cases} \frac{1}{n_s n_s}, & x_i, x_j \in D_s \\ \frac{1}{n_t n_t}, & x_i, x_j \in D_t \\ -\frac{1}{n_s n_t}, & \text{otherwise} \end{cases}$$

(4)

2019/10/13 20:36



$$Q_s(y_s|x_s) = \frac{P_s(x_s|y_s)P_s(y_s)}{P_s(x_s)} \rightarrow P_s(y_s) \text{ minimize } \rightarrow Q_s(y_s|x_s) \text{ and } Q_t(y_t|x_t)$$

### (3) Conditional Distribution Adaptation

$Q_s(x_s|y_s)$  and  $Q_t(x_t|y_t)$

生成 target data 的伪标签

将在有标签的源域数据上训练的基本分类器，应用到无标签目标域数据  
用 MMD(修正) 测量类条件分布  $Q_s(x_s|y_s=c)$  和  $Q_t(x_t|y_t=c)$  之间的距离

$$\left\| \frac{1}{n_s^{(c)}} \sum_{x_i \in D_s^{(c)}} A^T x_i - \frac{1}{n_t^{(c)}} \sum_{x_j \in D_t^{(c)}} A^T x_j \right\|^2 = \text{tr}(A^T X M c X^T A) \quad (5)$$

类间 class  $c \in \{1, \dots, C\}$

$$D_s^{(c)} = \{x_i : x_i \in D_s \wedge y_i(x_i) = c\}$$

$$D_t^{(c)} = \{x_j : x_j \in D_t \wedge \hat{y}(x_j) = c\}$$

MMD矩阵  $M_c$

$$n_s^{(c)} = |D_s^{(c)}|$$

$$n_t^{(c)} = |D_t^{(c)}|$$

$$(M_c)_{ij} = \begin{cases} \frac{1}{n_s^{(c)} n_s^{(c)}}, & x_i, x_j \in D_s^{(c)} \\ \frac{1}{n_t^{(c)} n_t^{(c)}}, & x_i, x_j \in D_t^{(c)} \\ \frac{1}{n_s^{(c)} n_t^{(c)}}, & \begin{cases} x_i \in D_s^{(c)}, x_j \in D_t^{(c)} \\ x_j \in D_s^{(c)}, x_i \in D_t^{(c)} \end{cases} \\ 0, & \text{otherwise} \end{cases} \quad (6)$$

最小化 (3) 和 (5) 来最大化 (2)

将 (3), (5) 打并列 (2) 中

$$\begin{aligned} \text{optimization} \quad & \min \sum_{c=0}^C \text{tr}(A^T X M c X^T A) + \lambda \|A\|_F^2 \quad (7) \\ & A^T X X^T A = I \\ & + \text{tr}(\lambda A^T A) \quad \text{义端利高} \end{aligned}$$

kernelization 核化

$$x \rightarrow \phi(x) \quad \phi(x) = [\phi(x_1), \dots, \phi(x_n)], \quad K = \phi(x)^T \phi(x) \in \mathbb{R}^{n \times n}$$

kernel-JDA

$$\begin{aligned} \min \quad & \sum_{c=0}^C \text{tr}(A^T K M c K^T A) + \lambda \|A\|_F^2 \\ & A^T K K^T A = I \end{aligned}$$

$$A \in \mathbb{R}^{n \times k}$$

2019/10/13 20:37



$$\operatorname{tr}(A^T X \sum_{c=0}^C M_c X^T A + \lambda I A) + \operatorname{tr}(I - A^T X H X^T A) \Phi$$

迭代 用 TDA 为目标域数据生成 tabel, 然后以此作为伪标签, 迭代运行 TDA 直到收敛

对(1)式求拉格朗日函数

$$L = \operatorname{tr}(A^T (X \sum_{c=0}^C M_c X^T + \lambda I) A) + \operatorname{tr}(I - A^T X H X^T A) \Phi \quad (1)$$

$$\Phi = \operatorname{diag}(\phi_1, \phi_2, \dots, \phi_k) \in R^{k \times k}$$

$$\nabla \frac{\partial L}{\partial A} = 0 \text{ 得}$$

$$(X \sum_{c=0}^C M_c X^T + \lambda I) A = X H X^T A \Phi \quad (10)$$

求(10)式的前 k 个最小特征向量

$$\text{求 } \Phi \text{ 是 } A \quad A \Phi = P * V * D \quad \text{广义特征分解}$$

$$( ) A \quad X H X^T A \Phi$$

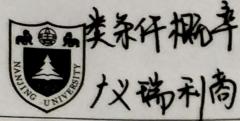
Computational Complexity

$$(1) \xrightarrow{\text{特征分解}} \xrightarrow{\text{构造 } M \times D \text{ 矩阵}} \xrightarrow{\text{训练分类器}}$$

$$O(Tkm^2 + Tch^2 + Tmn)$$

$$\begin{aligned} dL &= \operatorname{tr}(d(A^T)) (X \sum_{c=0}^C M_c X^T + \lambda I) A + \operatorname{tr}(A^T (X \sum_{c=0}^C M_c X^T + \lambda I) dA) - \operatorname{tr}(d(A^T) X H X^T A \Phi + A^T X H X^T dA \Phi) \\ &= \operatorname{tr}(A^T (X \sum_{c=0}^C M_c X^T + \lambda I) dA + \operatorname{tr}(A^T (X \sum_{c=0}^C M_c X^T + \lambda I)) dA - \operatorname{tr}(A^T X H X^T) dA - \operatorname{tr}(\Phi A^T X H X^T) dA \\ &= 2 \operatorname{tr}(A^T (X \sum_{c=0}^C M_c X^T + \lambda I)) dA - 2 \operatorname{tr}(\Phi A^T X H X^T) dA \\ &= 2 \operatorname{tr}((X \sum_{c=0}^C M_c X^T + \lambda I) A) dA - 2 \operatorname{tr}(X H X^T A \Phi) dA \\ &= 2 \operatorname{tr}((X \sum_{c=0}^C M_c X^T + \lambda I) A - X H X^T A \Phi) dA \end{aligned}$$

充分统计量



类条件概率

广义瑞利商

充分统计量

对于统计量  $t = T(X)$ , 若数据  $X$  在已知  $t = T(X)$  时的条件分布不依赖于参数  $\theta$ ,  
则称其是关于参数  $\theta$  的充分统计量

一个关于样本集  $D$  的函数, 其中包含了能有助于估计某种参数  $\theta$  的全部相关信息  $P(\theta | s, D) = P(\theta | s)$

扩展 MMD

MMD 与 PCA 集成

最小化输入数据以重构误差来学习

TCA 是 TDA 在  $C=0$  的情况下的特例

Input: Data  $X | X_s, X_t$ ,  $Y_s$ ,  $k$ ,  $\lambda$ .

Output: A, Z, classifier f.

Begin

(construct MMD matrix  $M_0$  by Eq. 14), set  $\{M_C := 0\}_{C=1}^C$  (选  $\{M_C\}$ )

repeat

对 eq 110) 进行特征分解, 取前  $k$  个最小的特征向量构成矩阵 A,  $Z := A^T X$

训练一个线性分类器  $f$  在  $\{(A^T x_i, y_i)\}_{i=1}^{n_s}$  上训练

在  $(A^T x_j)_{j=n_s+1}^{n_s+n_t}$  上预测生成伪标签  $\{\hat{y}_j = f(A^T x_j)\}_{j=n_s+1}^{n_s+n_t}$  并更新

(实际预测得到 vs 伪标签)

通过 16) 式更新 MMD 矩阵  $\{M_C\}_{C=1}^C$  (作为下次迭代的输入)

until Convergence